

DRL을 이용한 C-V2X 무선자원 관리

최민재¹⁾

한양대학교 미래자동차공학과¹⁾

C-V2X Radio Resource Management Using Deep Reinforcement Learning

Minjae Choi¹⁾

¹⁾Department of Automotive Engineering, Hanyang University, Seoul 04763, Korea

Abstract : This research is about the distributed congestion control (DCC) algorithm for Cellular vehicle-to-everything (C-V2X) communications using deep reinforcement learning (DRL) to improve the performance of european telecommunications standards institute's (ETSI) DCC method. C-V2X communication is one of the main technic for autonomous driving and as congestion can significantly affect its performance, it makes DCC algorithm essential for reliable performance. The DCC model trained with DRL to improve ETSI's DCC algorithm, utilizes the same packet generation time as ETSI's algorithm while considering vehicle density and channel busy ratio (CBR) as state inputs to maintain target communication performance. The results show improved performance compared to ETSI's algorithm. Also, the DRL trained model shows that the vehicle density mainly affect to the performance of communication. So the newly designed vehicle density-based algorithm, successfully enhances the performance of ETSI's DCC.

Key words : Channel busy ratio(채널 점유율), C-V2X(셀룰러 차량통신), Distributed congestion control(분산혼잡제어), Deep reinforcement learning(심층강화학습), ETSI(유럽전기통신표준협회), Vehicle density(차량 밀도)

1. 서론

Cellular vehicle-to-everything (C-V2X) 기술은 vehicle-to-vehicle, vehicle-to-infrastructure, vehicle-to-person, vehicle-to-network를 지원하는 차량 통신 기술로, 교통 안전성 향상, 교통 흐름 최적화, 그리고 자율주행 지원을 목표로 한다. 이 기술은 3rd generation partnership project (3GPP) release 14에서 소개된 이후 지속적으로 발전해 왔으며, mode3와 mode4 라는 두 가지 통신 모드가 주요 기술로 사용되고 있다. mode3의 경우 기지국이 차량간 통신 자원을 중앙에서 관리 및 할당하는 방식으로, 안정적인 기지국 연결을 전제로 하지만, 기지국 연결이 불안정하거나 없는 환경에서는 한계가 있다. 이를 보완하기 위해 mode4가 도입되었으며, 이는 차량이 스스로 자원을 선택하고 관리하는 분산형 자원 할당 방식이다. 이 방식은 sensing-based semi-persistent scheduling (SB-SPS)을 통해 기지국 없이도 통

신이 가능하다. 하지만 이러한 자율적인 자원 선택 방식은 간접 관리가 어렵고 네트워크 기반 방식에 비해 효율성이 떨어질 가능성이 있으며, 특히 고밀도 트래픽 환경에서는 통신 충돌 위험이 증가하는 문제가 있다.³⁾

또한 V2X 통신의 서비스 품질을 위해 요구되는 quality of service (QoS)가 제안되었는데, packet delivery ratio (PDR)을 80% ~ 95%로 유지해야 한다는 내용을 포함했다.²⁻³⁾ 하지만 mode4 방식은 고밀도 트래픽 환경에서 목표 PDR을 유지하기 어렵기 때문에 이를 해결하기 위해 european telecommunications standards institute (ETSI) 에서 distributed congestion control (DCC) 알고리즘을 제안했다.⁴⁾

하지만 ETSI가 제안한 DCC는 목표 QoS에 최적화 되지 않다는 한계가 있는데, 최근 이를 극복하기 위해 DRL을 이용해 새롭게 QoS에 최적화된 DCC를 설계한 연구가 있다. 해당 연구는 ETSI가 제안한 channel busy ratio (CBR)을 기반으로 한 기존 방식이 아닌, 차량 밀도를 활용한 새로운 접근으로 설

계했으며, 신호 발생 주기를 세밀히 조정하여 QoS에 적응적인 알고리즘을 학습했다.⁵⁾ 하지만 해당 연구는 deep reinforcement learning (DRL)을 학습시키기 위한 모델을 기존 방식들과는 별개로 새롭게 설계해, 새로운 알고리즘을 설계에는 성공했으나, DRL 학습의 특성인지 설계 자체의 효과인지 명확히 구분되지 않는다는 한계가 있다.

본 연구는 이러한 선행 연구의 한계를 극복하기 위해, ETSI가 제안한 DCC 알고리즘의 T_{gen}을 유지하면서 DRL을 활용하여 학습을 진행하여 기존 알고리즘과의 직접적인 성능 비교를 통해 DRL이 주어진 액션에서 기존 알고리즘보다 개선된 알고리즘을 찾아내는 데에 성공적으로 사용될 수 있음을 보이는 것이 목적이다. 이를 위해 본 연구에서는 ETSI에서 제공한 DCC 알고리즘을 분석해, 이를 기반으로 새로운 모델을 학습할 DRL 설계한다. 이후 학습된 모델을 분석해 새로운 알고리즘을 설계하고 ETSI의 DCC와 성능을 비교한다.

본 연구는 다음과 같은 의의가 있다.

- 1) ETSI에서 제안한 DCC 알고리즘의 한계를 심층적으로 분석하고, DRL을 활용하여 기존 알고리즘보다 효율적인 새로운 알고리즘 설계 가능성을 탐색하였다.
- 2) DRL 기반 알고리즘의 학술적 활용성을 확인하고, 기존 DCC와의 직접적인 성능 비교를 통해 향후 QoS를 최적화할 수 있는 설계 방안을 제시하였다.
- 3) 본 연구 결과는 C-V2X 기술 발전과 차세대 교통시스템의 신뢰성과 효율성 향상에 기여할 것으로 기대된다.

2. 연구 환경

본 연구는 Todisco 외 4인이 발표한 sidelink 5G-V2X 연구를 위한 오픈소스 시뮬레이터 WiLabV2 Xsim을 활용하였다.⁶⁾ Table 1에서 전체적인 시뮬레이션에 사용된 parameter를 확인할 수 있다.

3. ETSI의 DCC 알고리즘 해석 및 분석

ETSI에서 제안한 DCC 알고리즘은 가장 기본적인 DCC 알고리즘으로, CBR을 기준으로 차량의 channel occupancy ratio (CR) limit을 설정해 T_{gen}을 조절한다.⁴⁾ 본 연구에서는 해당 알고리즘을 비교군으로 삼아, 동일한 방식으로 T_{gen}을 조절하도록 DRL을 학습시켜 DRL 학습의 효율성을 직접적으로

Table 1 Simulation parameters

Parameter	Value
Density(ρ)	100~360 [veh/km]
Resource keep probability	0.8
Message size	300 [Byte]
Bandwidth	10 [MHz]
Road width	3.5 [m]
Mean speed of vehicles	50 [km/h]
TCR	200 [m]
Target PDR	85 [%], 90 [%]
MCS index	3
Minimum SINR(γ)	1.49 [dB]
Memory capacity	1000000
Mini-batch size	768
Minimum T _{gen}	100 [ms]

로 비교하고자 한다.

3.1 ETSI의 DCC 알고리즘 이론적 해석

ETSI에서 제안한 DCC 알고리즘은 개별 VUE가 각각 CBR을 관측해 CR limit을 선택한다. 이후 VUE의 CR이 선택된 CR limit을 넘어갈 경우, 해당 VUE는 패킷을 누락시켜 CR을 낮춘다. Table 2에 CR limit을 선택하는 상세한 수치가 있다.⁴⁾

Table 2 ETSI's DCC's CR limit configuration parameters⁴⁾

Measured CBR	CR limit
$0 < \text{CBR} \leq 0.3$	1
$0.3 < \text{CBR} \leq 0.65$	0.03
$0.65 < \text{CBR} \leq 0.8$	0.006
$0.8 < \text{CBR} \leq 1$	0.003

3.2 ETSI의 DCC 알고리즘 성능 분석

ETSI의 DCC 알고리즘을 기반으로 새로운 강화 학습 모델을 설계하기 위해, 조금 더 세부적으로 ETSI의 DCC 모델의 성능과 동작 원리를 분석해 보았다. 먼저 해당 DCC 알고리즘을 이용해 Table 1의 변수를 사용해 시뮬레이션을 돌려 알고리즘의 QoS를 평가하고, 그 원인을 분석했다.

3.2.1 성능 평가

알고리즘의 성능을 분석하기 위해 시뮬레이션을 통해 각각 DCC가 적용되지 않은 상태의 PDR과 ETSI의 DCC가 적용된 상태의 PDR을 구해 Fig. 1에서 비교했다.

결과적으로 ETSI에서 제공한 DCC는 어느정도 QoS를 개선하지만, 요구 QoS를 만족시키기에는 무척 부족한 성능을 보였다.




Fig. 1 Vehicle density vs PDR with/without ETSI DCC

3.2.2 원인 분석

Fig. 1의 결과가 나온 원인을 분석하기 위해, 각 T_{gen} 이 100ms, 166ms, 333ms으로 설정된 환경과 ETSI의 DCC가 적용된 환경의 차량밀도 별 평균 CBR을 분석해 Fig. 2에 나타내었다.

ETSI의 DCC 알고리즘은 최소 T_{gen} 이 100[ms]인 환경에서 평균 CBR을 0.65에 유지시키는 것을 확인했다. 이는 앞선 Table 2에 맞춰 올바르게 작동되고 있음을 의미한다. 하지만 이는 곧 평균 CBR을 유지시키는 것이 QoS 개선에 큰 영향을 주지 못한다는 의미한다.

3. DRL 모델 설계 및 분석

본 연구에서는 DRL 모델로 DQN을 사용했다. DQN은 기존 Q-Learning에 심층 신경망을 활용한 학습으로 고차원 데이터 처리, 일반화 성능 등을 크게 개선한 학습이다.⁷⁾

3.1 DCC를 학습할 DRL 모델 설계

3GPP는 상황별로 다양한 요구 QoS가 있음을 발표했다.⁸⁻⁹⁾ 본 논문에서도 이 점을 해결하기 위해 85%, 90% 2가지 목표 PDR에 맞는 훈련 data set을 사용해 2가지 모델을 학습한다. 또한, DRL 학습을 위해 state, action, reward를 설계해 table 3에 나타냈다.

1. State의 경우, 앞선 Fig. 2 통해 CBR을 이용한 제어기가 QoS 개선에 큰 영향을 주지 못한다는 것을 확인했다. 따라서, 차량 밀도를 추가해 2차원 state로 학습을 진행한다.
2. Action의 경우, ETSI의 DCC 알고리즘과의 직접적인 성능 비교를 위해 동일하게 사용하도록 설계한다. 따라서, Table 2에 서술된 알고리즘과 동일




Fig. 2 Vehicle density vs PDR with/without ETSI DCC

한 CR limit을 사용한다. 단, 본 연구에서는 시뮬레이션 환경을 최소 T_{gen} 100 [ms]로 설정하여 CR limit 0.03이 1과 동일하게 동작한다. 따라서 학습의 균형을 위해, CR limit 0.03을 제외한 3가지 action만을 사용한다.

3. Reward의 경우 요구 QoS에 적응되도록 설계한다. 학습 시 사용한 훈련 data set에서 이상적인 action을 취했을 시 관측되는 PDR과 실제로 선택한 action에 의해 관측된 평균 PDR의 차이를 증폭해 리워드로 사용한다. 이상적인 액션의 경우 훈련데이터에서 각 차량밀도 별 계산된 평균 PDR이 목표 PDR과 가장 가깝게 하는 액션을 이상적인 액션으로 설정했다.

Table 3 State, action, and reward settings in DRL training


State	Vehicle density, Average CBR
Action	CR limit = {1, 0.006, 0.003}
Reward	$1000 \times PDR_{\text{optimal}} - PDR_{\text{average}} $

3.2 DRL로 학습한 DCC 모델 성능 분석


Fig. 3 과 Fig. 4는 통해 학습된 모델이 시뮬레이션 상에서 CR limit을 제어하고, 결과적으로 평균 PDR을 제어하는 모습을 각 목표 PDR에 대해 그래프로 보여준다.

3.2.1 성능 평가

목표 QoS를 고려하지 않고, CR limit을 제어하게 될 경우, 단순히 CR limit을 1로 고정하면, T_{gen} 을 제어하지 않고 패킷을 최소 간격으로 보내게 되어 평균 PDR이 최저로 나오게 된다. 반면에 CR limit을 0.003으로 고정하게 될 경우, 채널 점유율을 낮추기 위해 T_{gen} 이 최대가 되어 PDR이 높아지게 된다. 이를 이용해 Fig. 3에서 차량밀도 별 평균 PDR의 upper bound와 lower bound를 도식화 하였다. 또한




(a) Target PDR = 85%




(b) Target PDR = 90%

Fig. 3 Vehicle density vs PDR of ETSI/trained DCC



(a) Target PDR = 85%



(b) Target PDR = 90%

Fig. 4 Vehicle density vs CR limit of ETSI/trained DCC

upper bound, lower bound와 각각 목표 PDR과의 교점의 사이가 우리가 주목해야 될 목표 QoS 구간이 된다. 이는 해당 구간을 벗어나게 될 경우, 이상적인 PDR이 upper bound와 lower bound를 따라가는 것으로 확인되어 CR limit의 별도의 제어가 필요없이 한가지 값으로 고정되기 때문이다.

결과적으로, Fig.3 과 Fig.4 를 통해 DRL을 이용해 학습된 DCC 모델이 목표 QoS 구간 내에서 의도대로 목표 PDR과 평균 PDR이 근접하도록 CR limit을 선택하는 것을 확인했다. 즉, ETSI의 DCC와 CR limit 제어를 이은 수치 중 선택하면서도, CR limit 선택 알고리즘을 DRL을 이용해 학습한 모델을 사용하는 것만으로 기존의 단순한 CBR기반 CR limit 제어를 통해 QoS개선하는 DCC 알고리즘을 기반으로 목표 QoS 구간 내에서 목표 QoS에 통신성능을 최적화시키는 DCC를 학습시키는 것이 가능하다는 것을 확인했다.

3.2.2 DRL로 학습한 DCC 모델 해석

Fig. 4에서 주목할 점은 DRL을 이용해 학습된 모델의 평균 CR limit 그래프가 action으로 제시된 3가지 CR limit 과 겹쳐지는 것을 통해 학습된 모델이 동일한 차량밀도에 대해 한가지 CR limit을 선택한다는 점을 알 수 있다는 것이다. 이는 즉, state로 CBR과 차량밀도를 모두 학습했음에도, PDR은 차량밀도의 영향을 더 크게 받는다는 것을 의미한다. 이는 Fig. 1과 Fig. 2를 통해 해석했던 ETSI의 CBR 기반 DCC 알고리즘이 낮은 성능을 보였던 이유와도 일치한다.

또한, Fig. 4를 통해 차량밀도 기반 QoS 적응형 DCC 알고리즘을 새롭게 설계할 수 있다. 이는 인공지능 학습의 문제점중 하나인 알고리즘이 black box내에서 학습되어 모델이 없는 알고리즘을 수행할 수 없다는 문제를 해결하며, 동시에 ETSI의 DCC 알고리즘을 효과적으로개선한다.

4. 차량밀도 기반 DCC 모델 설계 및 분석

앞선 DRL 훈련 모델을 바탕으로 ETSI의 DCC를 개선시킨 새로운 차량밀도 기반 QoS 최적화 DCC 알고리즘을 설계했다. Fig. 4를 통해, 각 목표 QoS 별 훈련된 DCC의 차량밀도에 따른 CR limit 선택을 해석하고 이를 기반으로 새로운 알고리즘을 설계했다.

4.1 차량밀도 기반 DCC 모델 설계

DRL을 통해 학습된 DCC가 각 목표 QoS에 따라서 선택한 차량밀도 별 CR limit을 정리해 Table 4에 나타내었다.

Table 4 Trained DCC's CR limit configuration parameters

Vehicle density	CR limit
$0 < \rho \leq 203$	1
$203 < \rho \leq 236$	0.006
$236 < \rho$	0.003

(a) Target PDR = 85%

Vehicle density	CR limit
$0 < \rho \leq 172$	1
$172 < \rho \leq 193$	0.006
$193 < \rho$	0.003

(b) Target PDR = 90%

4.2 성능 평가


새롭게 설계한 차량밀도 기반 QoS 최적화 DCC 알고리즘을 시뮬레이션 한 뒤 차량밀도 별 평균 PDR 을 Fig. 5에 도식화 했다. 결과적으로 Fig. 5는 Fig.3와 유사하게 나타났다. 이는 즉, 차량밀도 기반으로 설계된 DCC 알고리즘이 DRL을 통해 학습된 모델의 특성을 효과적으로 반영하고 있음을 의미한다.

4. 결론


1) ETSI에서 제안한 DCC 알고리즘을 DRL을 이용해 목표 QoS에 최적화 된 새로운 DCC 알고리즘으로 학습시켰다.

2) DRL을 이용해 학습된 알고리즘을 해석해 차량밀도 기반 목표 QoS에 최적화된 새로운 DCC 알고리즘을 설계했다.

3) 1-2) 결과를 통해 DRL을 이용해 기존의 DCC 알고리즘의 제어 알고리즘 만을 학습해 DCC알고리즘의 성능을 개선하는 모델을 설계할 수 있음을 확인했다.



(a) Target PDR = 85%



(b) Target PDR = 90%

Fig. 5 Vehicle density vs PDR of ETSI/vehicle density based DCC

5. 후기

본 연구는 현재 중요 기술인 차량의 자율 주행에 대해 조사하던 중 자율 주행에 필수적인 DCC 기술에 대해 알게되어 해당 기술을 조사하다, 마침 관심 있던 분야인 강화학습과 해당 주제를 연관지어 선행 연구를 한 분과 연이 닿아 시작하게 됐다.

본격적인 연구 시작 후, 맞이한 문제는 연구 초에 CBR만을 state로 설정했었다는 점이였다. 하지만 이는 오히려 ETSI의 DCC가 CBR 기반 알고리즘으로 인해 성능을 내지 못한다는 점을 알게 해주었고, 연구의 방향성을 더 좋은 방향으로 잡게 해주는 계기가 되었다.

본 연구를 진행하며 아쉬웠던 점은 ETSI의 DCC 알고리즘이 너무 기초적이라 DRL을 이용한 학습이 크게 유의미하지 않다는 점이다. 향후에는 더욱 복잡한 모델을 기반으로 학습, 혹은 더 많은 state에 대해 학습을 진행해 QoS에 영향을 주는 환경에 대해 분석하는 연구를 진행해보고 싶다.

References

- 1) 3GPP, "Study on LTE-based V2X services," TR 36.885 v14.0.0, Jun. 2016.
- 2) 3GPP, "Service Requirements for V2X Services," TS 22.185 v14.0.0, Jun. 2018.
- 3) 3GPP, "Study on LTE support for Vehicle to Everything (V2X) services," TR 22.885 v14.0.0, Dec. 2018.
- 4) ETSI, "Intelligent Transport Systems (ITS); Congestion Control Mechanisms for the C-V2X PC5 Interface; Access Layer Part," TS 103 574 V1.1.1, Nov. 2018.
- 5) W. Yang, B. Jeon, C. Mun and H. Jo, "Cellular-V2X QoS adaptive distributed congestion control: A deep Q network approach," 2023 IEEE 20th Consumer Communications & Networking Conference (CCNC), pp. 967-968, 2023.
- 6) V. Todisco, S. Bartoletti, C. Campolo, A. Molinaro, A. O. Berthet and A. Bazzi, "Performance analysis of sidelink 5G-V2X mode 2 through an open-source simulator," IEEE Access, Vol. 9, pp. 154-168, 2021.
- 7) V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra and M. Riedmiller, "Human-level control through deep reinforcement learning," Nature, Vol. 518, pp. 529-533, Feb. 2015.
- 8) 3GPP, "Study on enhancement of 3GPP support for 5G V2X services," TR 22.886 v15.3.0, Sep. 2018.
- 9) 3GPP, "Enhancement of 3GPP support for V2X scenarios," TS 22.186 v15.3.0, Jun. 2018.