

DRL을 이용한 C-V2X 무선자원 관리 - 부록

ETSI 신호 발생주기 계산 공식

1. 차량의 혼잡도를 고려한 CR_{limit} 선정

$$CR_{limit} = 1, \quad \text{if } CBR \leq 0.65$$
$$CR_{limit} = 0.006, \quad \text{if } 0.65 < CBR \leq 0.8$$
$$CR_{limit} = 0.003, \quad \text{if } 0.8 < CBR$$

2. 해당 CR_{limit} 에 대한 신호 발생주기 계산


$$T_{gen-DCC} = \frac{n_{subch-packet} T_{subframe}}{n_{sub} CR_{limit}}$$
$$T_{gen} = \max(T_{gen-DCC}, T_{gen-app})$$

학습에 사용된 매개 변수



Density(ρ)	100~360 [veh/km]
Resource keep probability	0.8
Message size	300 [Byte]
Bandwidth	10 [MHz]
Roadwidth	3.5 [m]
Mean speed of vehicles	50 [km/h]
TCR	200 [m]
Target PDR	85 [%], 90 [%]
MCS index	3
Minimum SINR(γ)	1.49 [dB]
Memory capacity	10^6
Mini-batch size	768

DRL을 이용한 C-V2X 무선자원 관리 - 부록



포스터에 활용된 그래프





Rho-Average CBR



Rho-Average PDR (DQN) ($PDR_{target} = 85\%, 90\%$)



Rho-Tgen ($PDR_{target} = 85\%, 90\%$)



Rho-Average PDR (Policy) ($PDR_{target} = 85\%, 90\%$)

DRL을 이용한 C-V2X 무선자원 관리

C-V2X radio resource management using
Deep Reinforcement Learning

한양대학교 미래자동차공학과
4학년 안재욱 최민재
지도교수 조한신

연구 배경

- 차량과 모든 인프라 간의 통신환경에서 혼잡을 해소하기 위해 분산혼잡제어(DCC) 기술이 필요함
- ETSI에서 제공한 DCC의 Algorithm은 통신성능지표인 PDR을 기준 성능 이상으로 유지하는데 미흡한 성능을 보임

연구 목적

- 심층강화학습을 이용해 기존 ETSI에서 제공한 DCC의 성능을 올려줄 새로운 모델 학습하기
- 학습된 모델을 토대로 새로운 DCC algorithm 설계 및 제안

ETSI의 DCC Algorithm 분석




Fig. 1. 차량 밀도별 평균 CBR

- ETSI는 통신혼잡도(CBR)를 기준으로 신호발생주기를 조절함
- 실제로는 CBR을 0.65로 유지시키도록 동작됨
- CBR만을 이용한 algorithm이 낮은 성능의 주요 원인이라 보임

$$\begin{aligned} T_{gen} &= 100 \text{ [ms]}, & \text{if } CBR \leq 0.65 \\ T_{gen} &= 166 \text{ [ms]}, & \text{if } 0.65 < CBR \leq 0.8 \\ T_{gen} &= 333 \text{ [ms]}, & \text{if } 0.8 < CBR \end{aligned}$$

모델 학습을 위한 DRL 설계

- 본 연구에서 사용할 심층강화학습으로는 DQN을 선택함
- State는 분석을 토대로, CBR 외에 차량밀도 또한 사용함
- Action은 ETSI와 policy를 직접적으로 비교하기 위해 동일한 신호발생주기를 선택함
- Reward는 사전 설정한 $PDR_{optimal}$ 과 측정된 PDR의 차이를 증폭해서 사용
- $PDR_{optimal}$ 은 훈련 데이터 셋에서 목표 PDR과 가장 근접한 값으로 선정

State	Rho, Average CBR
Action	$T_{gen} = \{100 \text{ [ms]}, 166 \text{ [ms]}, 333 \text{ [ms]}\}$
Reward	$-1000 \times PDR_{optimal} - PDR_{average} $

DRL로 학습된 모델의 성능 분석




Fig. 2. 학습된 모델에서 관측된 차량 밀도별 평균 PDR ($PDR_{target} = 85\%, 90\%$)

- 도로 환경 시뮬레이터를 이용해 학습한 모델의 성능을 분석함
- Fig. 2을 통해 학습된 모델이 의도대로 ETSI에 비해 평균 PDR을 목표 PDR 근방으로 유지하는 것이 확인됨




Fig. 3. 차량밀도 변화에 따른 평균 신호발생주기 ($PDR_{target} = 85\%, 90\%$)

- Fig. 3을 통해, 학습된 모델이 선택한 Action을 분석함
- 학습된 모델이 같은 차량 밀도에 대해서 한가지 Action만을 선택하는 것이 확인됨
- 이를 통해 학습에 사용된 두 가지 State 중 차량 밀도만이 Action 선택에 영향을 미쳤을 것으로 분석됨
- 따라서 Fig. 3의 데이터를 기반으로 ETSI의 CBR 기반 algorithm이 아닌 차량 밀도 기반 algorithm을 설계함

새로운 algorithm 설계

- 두 가지 목표 PDR에 따라 각각 새로운 algorithm을 설계함
목표 PDR = 85%

$$\begin{aligned} T_{gen} &= 100 \text{ [ms]}, & \text{if } \rho < 203 \text{ [veh/km]} \\ T_{gen} &= 166 \text{ [ms]}, & \text{if } 203 \leq \rho < 236 \text{ [veh/km]} \\ T_{gen} &= 333 \text{ [ms]}, & \text{if } 236 \leq \rho \text{ [veh/km]} \end{aligned}$$

목표 PDR = 90%

$$\begin{aligned} T_{gen} &= 100 \text{ [ms]}, & \text{if } \rho < 172 \text{ [veh/km]} \\ T_{gen} &= 166 \text{ [ms]}, & \text{if } 172 \leq \rho < 193 \text{ [veh/km]} \\ T_{gen} &= 333 \text{ [ms]}, & \text{if } 193 \leq \rho \text{ [veh/km]} \end{aligned}$$

새로운 algorithm 성능 분석




Fig. 4. 새로운 algorithm에서 차량 밀도별 평균 PDR ($PDR_{target} = 85\%, 90\%$)

- 새롭게 설계한 algorithm과 DRL로 학습한 모델의 그래프가 일치하는 것을 확인함.
- 이를 통해 새롭게 제안된 알고리즘이 DRL로 학습된 모델의 특성을 효과적으로 반영하고 있음을 확인할 수 있음
- 이 결과는 ETSI의 DCC 알고리즘을 효과적으로 개선한 새로운 DCC 알고리즘을 제안했음을 시사함

연구 고찰

- DRL을 이용해 기존의 DCC algorithm을 개선한 새로운 algorithm을 발견하는데 충분히 활용될 수 있음을 보여줌
- ETSI의 3가지 신호 발생 주기 외에 더 세분화된 주기로 학습하면, 최적의 신호 발생 주기를 조절하는 알고리즘을 발견할 수 있을 것으로 예상됨